



Dedicatoria

Para mi perrito, porque tiene mucha hambre. Por todos los año.py que no logré terminar. Por mi pou llamado BAE, para que nunca más sufra de hambre aunque esté lejos de mi celular y finalmente... por el pequeño chechar (que será pequeño, pero es grande en nuestros corazones. Little Caesar's ¡Pizza! ¡Pizza! Hot-N Ready)

TABLA DE CONTENIDO

ÍNDICE DE TABLAS

ÍNDICE DE FIGURAS

Resumen

CAPÍTULO I

Introducción

1.1 Problema

La reconstrucción tridimensional de entornos urbanos tiene aplicaciones críticas en el modelado arquitectónico, la planificación civil, las simulaciones y el entretenimiento interactivo. Sin embargo, escalar los algoritmos actuales para reconstruir un entorno urbano real a partir de secuencias de video monocular presenta un desafío computacional prohibitivo.

Los algoritmos clásicos de fotogrametría, tales como *Structure-from-Motion* (SfM) y *Multi-View Stereo* (MVS), operan procesando la información de manera iterativa a nivel de píxel. Las ciudades están repletas de primitivas geométricas evidentes; la estructura está dominada casi por completo por superficies planas continuas como fachadas, muros y calzadas. Los algoritmos MVS no solo fallan catastróficamente en estas superficies planas debido a su inherente carencia de textura, sino que, además, la generación de una densidad masiva de puntos sobre un simple plano resulta innecesaria y altamente ineficiente, saturando la memoria del sistema sin aportar valor estructural a la malla final.

Para dimensionar esta limitación con datos realistas, se puede analizar el caso de Barranco, uno de los distritos más pequeños de la provincia de Lima, con una superficie de 2.808 km² [wikipedia2023barranco]. Si calculamos una red transitable aproximada de 30 km, se requerirían unos 90 km de recorrido asumiendo 3 pasadas por calle para garantizar la cobertura total de aceras y redundancia visual. A una velocidad de caminata de 5 km/h para evitar el *motion blur*, esto representa 18 horas de captura de video. Grabando a 30 fps para asegurar el solapamiento [pix4d2024videophotogrammetry], se obtiene un volumen de 1 944 000 fotogramas. Con 5 segundos por fotograma (siendo optimistas para la densificación MVS

de alta resolución en *hardware* de consumo [schonberger2016structure]), el procesamiento secuencial nos da 9 720 000 segundos. Esto equivale a 2700 horas o, en términos prácticos, 112 días (casi 4 meses) de cálculo ininterrumpido. Se nota entonces que, incluso para uno de los distritos más pequeños de Lima, el MVS tradicional es inviable.

Asimismo, alternativas algorítmicas modernas de renderizado neuronal como *3D Gaussian Splatting* (3DGS) [kerbl20233d] no solucionan este problema de escalabilidad. 3DGS es estrictamente un motor de optimización visual, no un extractor de geometría desde cero. Para evitar colapsar durante su entrenamiento, 3DGS depende de manera intrínseca de una inicialización geométrica previa (usualmente una nube semidensa provista por el propio SfM). Al depender de la fotogrametría clásica para arrancar, hereda su intratabilidad computacional.

1.2 Hipótesis y Planteamiento General

La conceptualización de esta investigación nace de una propuesta original fundamentada en la cognición espacial humana, cuya intuición ha sido validada recientemente por avances en el estado del arte. Del mismo modo en que un arquitecto es capaz de modelar y comprender un entorno utilizando únicamente abstracciones estructurales (como identificar contornos de muros y columnas) sin necesidad de proyectar mentalmente millones de puntos en el espacio, se propone que una inteligencia artificial puede imitar este comportamiento cognitivo. Esta premisa ha encontrado respaldo en investigaciones recientes; redes neuronales como Co-PLNet han demostrado la capacidad de abstraer *wireframes* eficientemente al haber sido entrenadas con conjuntos de datos anotados bajo criterios humanos.

A partir de este razonamiento, la hipótesis general postula que: **“Es posible reconstruir un entorno urbano en 3D basándose puramente en la abstracción de su arquitectura.”** Como consecuencia directa, este enfoque permite eludir por completo la costosa densificación masiva de puntos (MVS). Esta afirmación se justifica en que, al segmentar semánticamente los planos dominantes y extraer sus

fronteras estructurales (*wireframes*), el sistema algorítmico obtiene la información mínima y suficiente para completar matemáticamente los volúmenes del edificio.

Esta solución algorítmica se sostiene sobre las siguientes suposiciones fundamentales:

1. **El wireframe contiene la geometría esencial:** Sustentado en redes neuronales recientes como Co-PLNet [wang2026coplnet], se asume que los nodos y las líneas estructurales (*wireframes*) extraídos de una imagen en 2D brindan toda la información arquitectónica pura necesaria para trazar las fronteras físicas de los edificios.
2. **La semántica define la planaridad:** Avalado por modelos del estado del arte en segmentación de planos urbanos (como PlaneRCNN [liu2019planercnn] y ZeroPlane [liu2025zeroplane]), es empíricamente factible identificar qué regiones de la imagen corresponden a planos arquitectónicos, permitiendo aislar y tratar matemáticamente a cada *cara* de manera independiente.
3. **Fusión para el completado directo:** Esta es la principal interrogante a validar durante la investigación. Se plantea que, una vez reconocidas estas *caras* semánticas, se pueden utilizar exclusivamente los puntos estructurales conocidos de sus fronteras para completar matemáticamente el polígono tridimensional, tal como lo haría un arquitecto al proyectar un plano vacío.

1.3 Objetivos de Investigación

1.3.1 Objetivo General

Desarrollar una arquitectura computacional de reconstrucción tridimensional sustentada en la abstracción semántica y geométrica, que viabilice el modelado estructural del distrito de Barranco mediante el uso colaborativo de videos monoculares, reduciendo drásticamente la complejidad de procesamiento y eliminando la dependencia de la densificación clásica.

1.3.2 Objetivos Específicos

1. Diseñar un algoritmo híbrido de *tracking* y extracción estructural basado en redes neuronales profundas (nodos y *wireframes*) que evada los descriptores de textura tradicionales.
2. Implementar un flujo de procesamiento geométrico que inyecte restricciones semánticas (segmentación de planos) para completar matemática y directamente las caras del edificio, eludiendo por completo la fase de MVS.
3. Construir un sistema de indexación y alineación topológica mediante Optimización de Grafo de Poses (PGO), asistido por restricciones absolutas GPS, para ensamblar trayectorias locales inconexas dentro de un mapa global consistente de forma asíncrona.

CAPÍTULO II

Revisión Crítica de la Literatura

La reconstrucción tridimensional de entornos urbanos ha estado históricamente dominada por métodos que intentan recuperar la geometría a partir de imágenes de manera exhaustiva. Sin embargo, las ciudades modernas son complejas, grandes y tienen texturas repetitivas.

En este capítulo se revisan los avances en la reconstrucción visual, ordenados cronológicamente y por temática. El objetivo es identificar qué funciona, por qué falla en ciertos escenarios y cómo las nuevas tecnologías lo solucionan.

2.1 De la Fotogrametría Clásica a la Representación Neural (2016 - 2023)

2.1.1 El Cuello de Botella del MVS Clásico

El paradigma clásico de reconstrucción 3D está representado principalmente por **COLMAP** [schonberger2016structure] (2016). Funciona a través de algo llamado Structure-from-Motion (SfM) para calcular la posición de las cámaras y lo junta con Multi-View Stereo (MVS), que juntos permiten la generación y densificación de una nube de puntos de la escena. Sirve para recuperar la geometría asumiendo que hay suficientes correspondencias visuales claras entre las imágenes.

Una desventaja grande del MVS clásico es que, con el fin de ser robusto, ejecuta un emparejamiento exhaustivo a nivel de píxel entre todas las imágenes, es decir, su costo computacional es cuadrático. En entornos urbanos, donde predominan las fachadas repetitivas, ventanas reflectantes y superficies sin textura, este enfoque falla. Además, el costo computacional de densificar punto por punto vuelve inviable mapear trayectos largos de manera eficiente.

2.1.2 NeRF y la dependencia de 3D Gaussian Splatting

Buscando una alternativa a los puntos discretos, en 2020 surgieron los Neural Radiance Fields (**NeRF**) [mildenhall2020nerf]. Estos modelos codifican la geometría y la iluminación de una escena en los pesos de una red neuronal. El problema es que para renderizar una imagen ejecutan un rastreo de rayos continuo, lo que hace que entrenar y visualizar el modelo sea excesivamente lento para aplicaciones prácticas.

Para solucionar el problema del renderizado, en 2023 se introdujo **3D Gaussian Splatting (3DGS)** [kerbl20233d]. Este método funciona representando la escena con millones de gaussianas tridimensionales que se proyectan directamente en la pantalla, logrando una visualización en tiempo real.

Sin embargo, una desventaja grande de 3DGS es que, con el fin de evitar colapsar durante el entrenamiento y generar artefactos (*floaters*), depende intrínsecamente de una inicialización geométrica casi perfecta. Es decir, 3DGS necesita arrancar con una nube de puntos previa (usualmente proveniente del lento SfM de COLMAP). En resumen:

- 3DGS acelera drásticamente el renderizado.
- Pero hereda el cuello de botella del MVS clásico, ya que no puede entender la geometría inicial por sí solo.

2.2 Modelos Fundacionales y Superación del SfM (2024)

2.2.1 DUS3R: Reconstrucción sin Poses

Para romper la dependencia del SfM clásico, en 2024 surgió **DUS3R** [wang2024dust3r]. Este es un modelo fundacional que funciona planteando la reconstrucción como un problema de regresión directa de mapas 3D. A diferencia de COLMAP, DUS3R no requiere conocer ni estimar las poses de la cámara previamente.

Funciona a través de redes Transformers que extraen características profundas de un par de imágenes y las alinean de forma densa. Esto le permite recuperar la geometría incluso en superficies lisas o repetitivas donde el MVS clásico falla.

Cuando se junta DUS3R con 3DGS, ocurre algo clave:

- DUS3R proporciona los priors geométricos robustos de manera rápida.
- Se elimina la necesidad de ejecutar horas de SfM clásico.
- 3DGS recibe una inicialización sólida, solucionando su principal debilidad y permitiendo optimizar escenas urbanas sin colapsar.

2.3 Abstracción Semántica y Estructuras Planares (2019 - 2025)

2.3.1 Extracción Geométrica y Emparejamiento Semántico

Mantener y optimizar millones de puntos o gaussianas para representar una ciudad sigue siendo ineficiente, porque la mayoría de los edificios son estructuras simples (paredes, techos, calles). El enfoque *top-down* busca extraer directamente estas geometrías.

En 2019, **PlaneRCNN** [liu2019planercnn] propuso detectar planos estructurales en las imágenes, prediciendo máscaras y parámetros de profundidad. Sirvió para sentar las bases de la representación de entornos tipo *Manhattan-world*, pero su desventaja grande era que dependía de heurísticas que fallaban al intentar emparejar estos planos bajo cambios bruscos de perspectiva.

Para solucionar la robustez del seguimiento geométrico, surgió **GlueStick** [pelaez2023gluestick] (2023). Funciona combinando el emparejamiento de puntos clave y líneas estructurales en un solo paso usando atención cruzada, que juntos permiten conectar imágenes con grandes cambios de perspectiva. Esto resuelve el problema de los giros bruscos en recorridos urbanos donde los métodos convencionales pierden el rastro.

2.3.2 Reconstrucción Planar Moderna y Splatting Semántico

Con la madurez de los Transformers, la extracción de geometría abstracta mejoró radicalmente. **ZeroPlane** [liu2025zeroplane] (2025) funciona a través del desacoplamiento de la predicción de la dirección de un plano (su vector normal) y su distancia absoluta. Al separarlo matemáticamente, evita los errores de optimización y logra recuperar representaciones algebraicas explícitas a partir de una sola imagen de manera directa.

Finalmente, para unir la abstracción planar con la eficiencia volumétrica, apareció **PlanarSplatting** [tan2024planarsplatting] (2024/2025). Funciona forzando a las gaussianas a alinearse con las superficies planas extraídas de la escena. Al aplicar este prior geométrico sobre el 3DGS, juntos logran reconstruir la geometría estructural sin depender de puntos tridimensionales, tal como se aprecia en la Figura ??.




FIGURA 2.1: Arquitectura general de PlanarSplatting. El método optimiza primitivas planas 3D directamente desde imágenes multi-vista empleando renderizado diferenciable. Esto permite evadir la densificación clásica de MVS y obtener modelos ultrarrápidos (Fuente: [tan2024planarsplatting]).

En síntesis, la inyección de restricciones planas permite:

- Reconstruir la superficie en tiempos ínfimos (minutos).

- Eliminar por completo la dependencia del MVS clásico para la inicialización.
- Extraer directamente mallas con texturas limpias y sin "geometría basura", ideales para la reconstrucción urbana masiva.

CAPÍTULO III

Marco Teórico

Este capítulo establece las bases teóricas y matemáticas de la arquitectura propuesta para la reconstrucción 3D a escala urbana. Se abordarán los conceptos desde la fotogrametría clásica hasta los paradigmas modernos de segmentación semántica y optimización geométrica planar.

3.1 Geometría Multivista Clásica

La geometría multivista establece los fundamentos matemáticos para inferir la estructura tridimensional de una escena a partir de múltiples proyecciones bidimensionales. Esta disciplina constituye la base algorítmica de la fotogrametría clásica y los sistemas de reconstrucción 3D [hartley2003multiple]. A continuación, se detallan los principios teóricos fundamentales que componen el flujo de trabajo estándar en visión computacional.

3.1.1 Geometría Epipolar y Matrices Fundamental y Esencial

La geometría epipolar describe la relación proyectiva geométrica intrínseca entre dos vistas de la misma escena tridimensional. Sea un punto 3D $\mathbf{X}$ que se proyecta en los planos de imagen de dos cámaras, obteniendo las coordenadas homogéneas $\mathbf{x}$ y $\mathbf{x}'$.

Cuando ambas cámaras están calibradas internamente, la relación espacial entre ellas (descrita por una matriz de rotación $\mathbf{R}$ y un vector de traslación $\mathbf{t}$) queda encapsulada en la *Matriz Esencial* $\mathbf{E} \in \mathbb{R}^{3 \times 3}$:

$$\mathbf{E} = [\mathbf{t}]_{\times} \mathbf{R} \tag{III.1}$$

donde $[\mathbf{t}]_{\times}$ representa la matriz antisimétrica asociada al vector de traslación. La restricción epipolar establece que las coordenadas de imagen normalizadas, $\hat{\mathbf{x}}$ y $\hat{\mathbf{x}}'$, deben satisfacer:

$$\hat{\mathbf{x}}'^T \mathbf{E} \hat{\mathbf{x}} = 0 \quad (\text{III.2})$$

En el caso general de cámaras no calibradas, se formula la *Matriz Fundamental* $\mathbf{F}$, que absorbe las matrices de parámetros intrínsecos $\mathbf{K}$ y $\mathbf{K}'$ de la primera y segunda cámara respectivamente:

$$\mathbf{F} = \mathbf{K}'^{-T} \mathbf{E} \mathbf{K}^{-1} \quad (\text{III.3})$$

Esto generaliza la restricción epipolar para coordenadas de píxel sin normalizar:

$$\mathbf{x}'^T \mathbf{F} \mathbf{x} = 0 \quad (\text{III.4})$$

Geoméricamente, esta ecuación significa que, dado un punto $\mathbf{x}$ en la primera vista, su correspondiente $\mathbf{x}'$ en la segunda vista está restringido a yacer sobre la línea epipolar $\mathbf{l}' = \mathbf{F}\mathbf{x}$. Esta propiedad es crucial, ya que reduce el problema de correspondencia estéreo de una búsqueda bidimensional a una búsqueda unidimensional.

3.1.2 Structure-from-Motion (SfM) y Bundle Adjustment

Structure-from-Motion (SfM) es el proceso computacional que estima simultáneamente la estructura 3D dispersa (sparse) de la escena y las trayectorias de las cámaras (sus parámetros extrínsecos) a partir de un conjunto de imágenes [schonberger2016structure]. El algoritmo extrae características locales (como SIFT o SURF), establece correspondencias entre vistas y recupera iterativamente las poses de las cámaras y los puntos tridimensionales.

Para mitigar la acumulación de errores de estimación y refinar conjuntamente las poses de cámara y la geometría de la escena, se aplica *Bundle Adjustment* (BA) [triggs1999bundle]. BA es formulado como un problema de optimización no lineal

de gran escala que busca minimizar el *error de reproyección*. Este error es la distancia euclidiana entre las coordenadas 2D observadas empíricamente en las imágenes y las proyecciones teóricas de los puntos 3D estimados.

Dadas m cámaras con matrices de proyección $\mathbf{P}_i$ y n puntos 3D $\mathbf{X}_j$, la función de costo objetivo a minimizar es:

$$E(\mathbf{P}, \mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n v_{ij} \|\mathbf{x}_{ij} - \pi(\mathbf{P}_i, \mathbf{X}_j)\|^2 \quad (\text{III.5})$$

donde $\mathbf{x}_{ij}$ es la medición del punto j en la imagen i , $\pi(\cdot)$ denota el operador de proyección no lineal de la cámara, y $v_{ij} \in \{0, 1\}$ es una variable indicadora binaria de la visibilidad del punto $\mathbf{X}_j$ en la cámara i . Esta función se minimiza típicamente empleando el algoritmo iterativo de Levenberg-Marquardt, el cual explota eficientemente la matriz Jacobiana dispersa característica de este problema.

3.1.3 Multi-View Stereo (MVS) y el Cuello de Botella Computacional

Mientras que SfM proporciona un esqueleto 3D disperso y la orientación de las cámaras, *Multi-View Stereo* (MVS) utiliza estos parámetros calculados para inferir la geometría subyacente de toda la superficie observada, generando una representación densa (mapas de profundidad o nubes de puntos densificadas) [seitz2006comparison].

Los algoritmos MVS operan buscando emparejamientos a nivel de píxel a través de las vistas basándose en medidas de consistencia fotométrica (ej. Correlación Cruzada Normalizada, NCC), guiados por las restricciones de la geometría epipolar y suposiciones de suavidad espacial e interpolación como en algoritmos modernos basados en *PatchMatch*.

Densificación como Cuello de Botella: En los pipelines de reconstrucción clásicos, el MVS representa el cuello de botella computacional más severo [schoenberger2016mvs]. Este proceso de densificación exige evaluar la fotoconsistencia para cada píxel de una imagen de referencia, cotejándolo contra múltiples imágenes superpuestas. A altas resoluciones (imágenes de varios megapíxeles), el

espacio volumétrico de hipótesis de profundidad a explorar escala masivamente. Calcular las métricas de correlación sobre múltiples parches de píxeles para miles de millones de combinaciones espaciales implica un consumo exorbitante de ancho de banda de memoria y procesamiento aritmético. Esto provoca que la densificación clásica dependa invariablemente de una ejecución paralela intensiva (generalmente en GPUs) y requiera un tiempo de cómputo que frecuentemente imposibilita su despliegue en aplicaciones estrictas de tiempo real.

3.2 Segmentación Semántica y Detección

La extracción de información semántica a partir de imágenes digitales es uno de los desafíos centrales en la visión por computadora. Este proceso implica la transición de una representación de bajo nivel (matrices de píxeles) a una abstracción de alto nivel donde se identifican, localizan y delinean objetos de interés. En esta sección se analizan dos paradigmas fundamentales: la detección de objetos en tiempo real mediante la arquitectura YOLO, y la segmentación semántica guiada por *prompts* a través de los modelos SAM y FastSAM.

3.2.1 YOLO (You Only Look Once): Detección en Tiempo Real

El modelo YOLO (You Only Look Once) [redmon2016yolo] revolucionó la detección de objetos al replantear la tarea como un único problema de regresión directo desde los píxeles de la imagen hasta las coordenadas de las cajas delimitadoras (*bounding boxes*) y las probabilidades de clase, eliminando la necesidad de los métodos tradicionales de propuestas de regiones.

A nivel matemático, YOLO divide la imagen de entrada en una cuadrícula de $S \times S$. Si el centro de un objeto cae dentro de una celda de la cuadrícula, dicha celda es responsable de detectarlo. Cada celda predice B cajas delimitadoras y sus respectivas puntuaciones de confianza (*confidence scores*). La confianza refleja tanto la probabilidad de que la caja contenga un objeto como la precisión de dicha caja,

definida como:

$$\text{Confianza} = \text{Pr}(\text{Objeto}) \times \text{IoU}_{\text{pred}}^{\text{truth}} \quad (\text{III.6})$$

donde IoU es la Intersección sobre la Unión entre la caja predicha y la verdad fundamental.

Cada caja delimitadora consta de cinco predicciones: $(x, y, w, h, \text{confianza})$. Además, cada celda predice las probabilidades condicionales de clase C , es decir, $\text{Pr}(\text{Clase}_i | \text{Objeto})$.

El aprendizaje del modelo se rige por una función de pérdida multiparte (*multi-part loss function*) basada en la suma de los errores cuadráticos, que optimiza simultáneamente la localización y la clasificación:

$$\begin{aligned} \mathcal{L} = & \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ & + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{obj}} \left[(\sqrt{w_i} - \sqrt{\hat{w}_i})^2 + (\sqrt{h_i} - \sqrt{\hat{h}_i})^2 \right] \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{K}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2 \\ & + \sum_{i=0}^{S^2} \mathbb{K}_i^{\text{obj}} \sum_{c \in \text{clases}} (p_i(c) - \hat{p}_i(c))^2 \end{aligned} \quad (\text{III.7})$$

donde $\mathbb{K}_{ij}^{\text{obj}}$ indica si la j -ésima caja de la celda i es responsable de la predicción, y λ_{coord} , λ_{noobj} son factores de penalización que balancean los errores de localización frente a las clasificaciones. Esta arquitectura permite abstraer espacial y semánticamente la imagen en una sola pasada (*forward pass*), posibilitando una inferencia a altas velocidades en tiempo real.

3.2.2 Modelos Fundacionales de Segmentación: SAM y FastSAM

Mientras que YOLO abstrae la imagen semánticamente en regiones rectangulares, la segmentación semántica fina busca una abstracción a nivel de píxel. El *Segment Anything Model* (SAM) [kirillov2023sam] es un modelo fundacional que

permite una segmentación generalizable y robusta (*Zero-Shot*) mediante indicaciones (*prompts*).

La arquitectura de SAM consta de tres componentes principales: un codificador de imágenes (*Image Encoder*), un codificador de *prompts* y un decodificador de máscaras. El codificador de imágenes está basado en Vision Transformers (ViT) [dosovitskiy2020image]. En un ViT, la imagen de entrada $X \in \mathbb{R}^{H \times W \times C}$ se divide en una secuencia de parches 2D aplanados $x_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$, donde (P, P) es la resolución del parche y $N = HW/P^2$ es el número total de parches. Éstos se proyectan linealmente a un espacio latente de dimensión D , sumando *embeddings* posicionales para preservar la topología espacial original.

El núcleo de la abstracción semántica en el ViT es el mecanismo de atención propia (*self-attention*), que calcula la correlación entre parches distantes. A nivel matemático, las matrices de Consultas (*Queries* Q), Claves (*Keys* K) y Valores (*Values* V) se calculan mediante transformaciones lineales, formulando la atención como:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (\text{III.8})$$

donde d_k es la dimensión de las claves. Esta operación genera representaciones densas y semánticamente globales de la imagen. Simultáneamente, el codificador de *prompts* proyecta coordenadas (puntos o cajas) y textos al mismo espacio latente continuo. Finalmente, el decodificador fusiona los *embeddings* de imagen y *prompt* mediante atención cruzada (*cross-attention*) para generar probabilísticamente máscaras de segmentación de alta precisión.

Pese a su asombroso poder de abstracción, la complejidad cuadrática del módulo de atención de ViT restringe el uso de SAM en dispositivos de tiempo real. Para resolver esto, Zhao et al. introdujeron **FastSAM** [zhao2023fast]. FastSAM reformula el paradigma dependiente de *prompts* de SAM y lo divide en dos etapas computacionalmente más eficientes:

1. **Segmentación de Instancias Densa:** Mediante una red convolucional (CNN) optimizada, específicamente YOLOv8-seg, la imagen completa se procesa para

extraer indiscriminadamente todas las instancias posibles en una sola pasada. Esto crea una abstracción a nivel semántico de todos los objetos en la imagen sin requerir *prompts* de entrada durante esta fase de extracción pesada.

2. **Correspondencia Guiada por *Prompts*:** Las indicaciones del usuario (puntos, cajas) se analizan matemáticamente y se emparejan a posteriori contra la colección precomputada de máscaras de instancia basándose en solapamientos espaciales y operaciones geométricas simples.

Este enfoque elimina la necesidad de los pesados cálculos repetitivos del decodificador Transformer guiado, permitiendo que FastSAM opere de manera comparable a SAM pero acelerando el tiempo de inferencia cerca de 50 veces, volviéndolo idóneo para aplicaciones robóticas y de *edge computing*.

3.3 Extracción de Características Estructurales y Matching

3.3.1 Del enfoque clásico a *Deep Features*

Históricamente, la extracción de características dependía de algoritmos fundamentados en heurísticas diseñadas manualmente, como SIFT (Scale-Invariant Feature Transform). SIFT detecta puntos de interés identificando extremos locales en una pirámide del espacio de escalas construida mediante la Diferencia de Gaussianas (DoG), y describe dichos puntos utilizando histogramas de gradientes locales orientados. Sin embargo, su eficacia disminuye considerablemente bajo condiciones de variaciones extremas de iluminación o escasez de texturas.

El cambio de paradigma hacia arquitecturas de aprendizaje profundo ha consolidado el uso de *Deep Features*, ejemplificado por modelos como SuperPoint [detone2018superpoint]. SuperPoint procesa una imagen de entrada $I \in \mathbb{R}^{H \times W \times 1}$ empleando un codificador convolucional (tipo VGG) para generar un tensor de características. Este tensor alimenta simultáneamente a dos cabezales (*decoders*): uno dedicado a la detección de puntos clave y otro a la descripción. Matemáticamente, el cabezal de descriptores produce un tensor semi-denso $\mathcal{D} \in \mathbb{R}^{H_c \times W_c \times D}$, donde

$H_c = H/8$, $W_c = W/8$ y la dimensionalidad del descriptor es $D = 256$. A través de una interpolación bicúbica, este tensor se sobremuestra a la resolución original $H \times W$. Posteriormente, se aplica una normalización L_2 a nivel de píxel para asegurar que cada descriptor $\mathbf{d} \in \mathbb{R}^D$ tenga norma unitaria ($\|\mathbf{d}\|_2 = 1$). Esta proyección es crítica, pues facilita que el *matching* posterior pueda ejecutarse eficientemente mediante el producto punto escalar.

3.3.2 Extracción de Nodos y Líneas (Co-PLNet) y Formación del *Wireframe*

Una representación estructural más robusta trasciende el uso exclusivo de puntos aislados para construir un *wireframe* (estructura alámbrica) $\mathcal{W} = (\mathcal{V}, \mathcal{E})$, un grafo bidimensional geométrico donde $\mathcal{V}$ es el conjunto de vértices (puntos clave o nodos) y $\mathcal{E}$ el conjunto de aristas (segmentos de línea).

Los enfoques convencionales extraen puntos y líneas de forma inconexa y aplican heurísticas de reconciliación *post-hoc*, lo que frecuentemente deriva en severas inconsistencias geométricas (ej. líneas que no intersecan ni culminan en nodos detectados). La arquitectura Co-PLNet (Collaborative Point-Line Network) [wang2026coplnet] resuelve esta divergencia planteando la extracción como un problema de *parsing* guiado por *prompts*.

Dentro de su formulación, el *Point-Line Prompt Encoder* (PLP-Encoder) mapea detecciones iniciales en características espaciales compactas que funcionan como restricciones matemáticas previas (*prompts*). A su vez, el *Cross-Guidance Line Decoder* (CGL-Decoder) utiliza un mecanismo de atención dispersa (*sparse attention*) condicionado por dichos *prompts*. De esta manera, la probabilidad conjunta de existencia de un segmento de línea $l_{ij} \in \mathcal{E}$ queda intrínsecamente condicionada por las distribuciones de probabilidad espacial de los nodos terminales $v_i, v_j \in \mathcal{V}$. Este intercambio iterativo de señales espaciales entre ramificaciones fuerza matemáticamente una consistencia geométrica de punto a línea directamente durante la inferencia, dando lugar al grafo o *wireframe* estructurado.

3.3.3 *Graph Matching* con GlueStick: Emparejamiento Topológico 2D-2D

Una vez contruidos los grafos $\mathcal{W}_A$ y $\mathcal{W}_B$ correspondientes a las imágenes I_A e I_B , el proceso de asociación exige considerar tanto la similitud en la apariencia local como la coherencia topológica global. GlueStick [pelaez2023gluestick] aborda este desafío mediante el uso de una Red Neuronal de Grafos (GNN) multicapa que unifica el *matching* de puntos y líneas.

La arquitectura alterna capas de auto-atención (para propagar el contexto espacial dentro de la misma imagen y a lo largo de las líneas conectadas) y mecanismos de atención cruzada (*cross-attention*) diseñados explícitamente para el *matching* entre grafos. Matemáticamente, en la capa de atención cruzada, los nodos y aristas de $\mathcal{W}_A$ actúan como consultas (queries), mientras que los elementos de $\mathcal{W}_B$ proveen claves (keys) y valores (values). Definidas las matrices $Q \in \mathbb{R}^{N_A \times d}$, y $K, V \in \mathbb{R}^{N_B \times d}$, la actualización de las características viene dictaminada por la ecuación de la atención:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d}} \right) V \quad (\text{III.9})$$

donde el factor de escala $\sqrt{d}$ modula la magnitud del producto interno y previene gradientes desvanecientes. Este mecanismo de 2D-2D *graph matching* enriquece el vector de cada elemento al atenderse fusionar las características de sus homólogos prospectivos en la imagen opuesta, *pegando* (gluing) la información visual y geométrica.

Finalmente, utilizando las representaciones conjuntas actualizadas, se computan dos matrices de afinidad: M_P para nodos y M_L para aristas. A fin de establecer asignaciones inyectivas (1 a 1), se maximiza la verosimilitud de las correspondencias mediante el algoritmo de Sinkhorn, modelándolo como un problema de transporte óptimo discreto que es resuelto a través de una capa bidireccional Dual-Softmax. Esto garantiza que el grafo topológico subyacente $\mathcal{W}_A$ se empareje de manera óptima y robusta con el de $\mathcal{W}_B$.

3.4 Optimización Robusta y Geometría Planar

Esta sección aborda los fundamentos geométricos de la representación de planos en el espacio tridimensional, las transformaciones bidimensionales asociadas y los métodos robustos necesarios para estimar dichos modelos matemáticos en presencia de ruido y valores atípicos (outliers). Finalmente, se introduce la suposición del mundo Manhattan, una restricción geométrica fundamental en entornos estructurados.

3.4.1 Ecuación del Plano en 3D

En el espacio tridimensional $\mathbb{R}^3$, un plano puede ser definido unívocamente mediante un vector normal unitario $\mathbf{n} = (n_x, n_y, n_z)^\top$ y su distancia perpendicular al origen d . La ecuación general del plano para un punto $\mathbf{X} = (X, Y, Z)^\top$ que pertenece a dicho plano se expresa como:

$$\mathbf{n}^\top \mathbf{X} + d = 0 \quad (\text{III.10})$$

donde $\|\mathbf{n}\| = 1$. Alternativamente, en coordenadas homogéneas, el plano se puede representar mediante un vector $\boldsymbol{\pi} = (n_x, n_y, n_z, d)^\top$, tal que para cualquier punto homogéneo $\tilde{\mathbf{X}} = (X, Y, Z, 1)^\top$ en el plano, se cumple la condición de incidencia $\boldsymbol{\pi}^\top \tilde{\mathbf{X}} = 0$.

3.4.2 Homografías: Transformaciones 2D-2D

Al observar un plano tridimensional desde diferentes perspectivas, la relación entre las proyecciones de los puntos en los planos de imagen se describe mediante una transformación proyectiva plana conocida como *homografía*. Dados los puntos en coordenadas homogéneas $\mathbf{x}$ en la primera imagen y $\mathbf{x}'$ en la segunda imagen, la homografía $\mathbf{H}$ (una matriz de 3×3 no singular y definida hasta un factor de escala)

relaciona ambos puntos mediante:

$$\mathbf{x}' \sim \mathbf{H}\mathbf{x} \quad (\text{III.11})$$

donde $\sim$ denota igualdad salvo por un factor de escala (igualdad proyectiva). Las homografías son esenciales para tareas como el mapeo de texturas, el ensamblaje de panoramas (*image stitching*) y la rectificación de imágenes.

3.4.3 Algoritmos Robustos: RANSAC y LO-RANSAC

En aplicaciones de visión por computadora, la correspondencia de puntos para estimar modelos (como planos u homografías) suele estar contaminada por correspondencias falsas (*outliers*). Para estimar el modelo correcto de forma robusta, se utiliza el algoritmo RANSAC (*Random Sample Consensus*) [fischler1981ransac].

RANSAC funciona muestreando iterativamente subconjuntos mínimos de datos para generar hipótesis del modelo y evaluando su consenso con el resto del conjunto de datos. El número de iteraciones N necesarias para garantizar con una probabilidad p que al menos una muestra mínima elegida (de tamaño s) esté libre de outliers es:

$$N = \frac{\log(1 - p)}{\log(1 - (1 - e)^s)} \quad (\text{III.12})$$

donde e es la probabilidad de que un punto aleatorio sea un outlier (proporción de outliers).

Sin embargo, el RANSAC estándar asume erróneamente que una muestra sin outliers siempre produce el mejor modelo posible, ignorando los efectos del ruido en los datos correctos (*inliers inexactos*). Para mitigar esto, se introdujo **LO-RANSAC** (*Locally Optimized RANSAC*) [chum2003locally]. Cada vez que LO-RANSAC encuentra un modelo mejor que el mejor modelo actual (con un mayor número de inliers), aplica una optimización local. Este paso ajusta los parámetros del modelo iterativamente utilizando todos los inliers detectados (por ejemplo, mediante

un ajuste de mínimos cuadrados), mejorando la precisión del modelo y convergiendo más rápidamente a la solución óptima real.

3.4.4 La Suposición de Mundo Manhattan (Manhattan-world Assumption)

En entornos urbanos y de interiores artificiales, la geometría de la escena suele presentar regularidades estructurales muy marcadas. La suposición de Mundo Manhattan (*Manhattan-world assumption*) [coughlan1999manhattan] simplifica la geometría asumiendo que la gran mayoría de las superficies (suelos, techos, paredes) son planas y están alineadas con uno de los tres ejes principales de un sistema de coordenadas cartesiano global y mutuamente ortogonal.

Bajo esta premisa, los vectores normales de los planos en la escena $\mathbf{n}_i$ tienden a ser paralelos a uno de los tres ejes principales $\{\mathbf{e}_x, \mathbf{e}_y, \mathbf{e}_z\}$. Esta restricción reduce significativamente la complejidad geométrica, mitigando la ambigüedad en escenas sin textura y facilitando la estimación de la orientación de la cámara (*pose*) mediante la detección de puntos de fuga ortogonales, así como la reconstrucción 3D robusta.

CAPÍTULO IV

Marco Metodológico: Arquitectura General del Sistema

Los algoritmos actuales de reconstrucción, como Multi View Stereo (MVS), operan bajo un paradigma de densificación exhaustiva. El problema principal de este enfoque es que resulta excesivamente costoso y redundante computacionalmente, ya que intenta densificar millones de píxeles sin entender la estructura de lo que está reconstruyendo. Generar estas nubes masivas se vuelve inmanejable para entornos urbanos a gran escala.

Para solucionar esto, el sistema propuesto plantea un modelo basado firmemente en la abstracción semántica y geométrica. En lugar de procesar a ciegas la profundidad, el enfoque busca comprender primero la escena arquitectónica para luego triangular únicamente las primitivas estructurales necesarias.

Este capítulo presenta un resumen rápido y estructurado de las fases que conforman la arquitectura propuesta, delineando la idea general del proyecto. Los detalles matemáticos y la implementación técnica profunda de cada fase se abordarán con muchísimo detalle en los capítulos posteriores.

4.1 Pipeline de Reconstrucción

El *pipeline* propuesto abandona por completo la densificación clásica basada en píxeles. Esto funciona dividiendo el problema en fases secuenciales, priorizando en todo momento la extracción de caras y fronteras arquitectónicas. El flujo de datos y los modelos involucrados en cada etapa se ilustran en la Figura ??.




FIGURA 4.1: Diagrama de flujo del pipeline de reconstrucción *top-down*. Se detallan las entradas, fases de procesamiento y salidas para la obtención de mallas poligonales limpias.

4.1.1 Fase 1: Preprocesamiento y Enmascaramiento Dinámico

Esta fase sirve para limpiar las secuencias de video de información no deseada. Funciona a través de modelos de inferencia rápida, como FastSAM o YOLO, los cuales detectan objetos dinámicos dentro de la escena (típicamente autos y peatones), tal como se ejemplifica en la Figura ??.

o ORB, porque son propensos a fallar en entornos repetitivos o sin textura.

Se utilizan arquitecturas neuronales de última generación, como Co-PLNet [wang2026coplnet], para extraer nodos clave y los *wireframes* estructurales en cada imagen. Como se observa en la Figura ??, la red identifica con precisión las esquinas y líneas arquitectónicas de la edificación.



FIGURA 4.3: Demostración de extracción conjunta de puntos y líneas sobre edificaciones reales utilizando Co-PLNet. Se observan los nodos estructurales en verde y las fronteras arquitectónicas en rojo (Fuente: Elaboración propia).

Posteriormente, se aplican arquitecturas de grafos, específicamente GlueStick [pelaez2023gluestick], para realizar un emparejamiento robusto conjunto de puntos y líneas. Esto permite calcular una triangulación dispersa inicial que estima la pose de la cámara.

4.1.3 Fase 3: Segmentación y Detección de Caras (Planos)

En esta etapa, el sistema inyecta restricciones semánticas para detectar y segmentar los planos arquitectónicos dominantes usando modelos especializados como ZeroPlane [liu2025zeroplane], PlaneRCNN [liu2019planercnn], o combinaciones robustas usando DUST3R [wang2024dust3r] y SAM. Como se ejemplifica en la Figura ??, estas arquitecturas son capaces de identificar y aislar matemáticamente las distintas instancias planas que componen la escena.



FIGURA 4.4: Demostración de segmentación de superficies planares. La imagen ilustra cómo la red infiere máscaras para cada instancia plana detectada. Cada color representa un plano geométrico distinto, facilitando la distinción entre superficies arquitectónicas y elementos ajenos (Fuente: [liu2019planercnn]).

Analíticamente, la segmentación de planos proporciona restricciones geométricas severas para la reconstrucción. Como se aprecia en la Figura ??, al asignar a cada píxel su pertenencia a una instancia plana específica, el sistema discrimina las superficies puramente arquitectónicas (fachadas, calzadas, muros) de las geometrías de alta entropía (como vegetación o mobiliario urbano). Esta clasificación semántica permite que las geometrías complejas sean excluidas de la optimización del plano

infinito, encapsulándolas temporalmente en volúmenes delimitadores (*bounding boxes*) para evitar que su topología irregular corrompa la instanciación matemática de las caras principales.

- **Resumen:** Se aíslan las caras planares útiles de las geometrías complejas garantizando que solo la estructura puramente arquitectónica guíe la reconstrucción 3D.

4.1.4 Fase 4: Completado de Caras y Fusión Temporal

El reto en este punto es lograr mallas continuas a partir del flujo de video. Esto se soluciona fusionando temporalmente las caras segmentadas que apuntan al mismo plano físico a lo largo de los *frames*.

Sobre estos *super-segmentos* fusionados, el sistema recupera los puntos estructurales conocidos provenientes del *wireframe* (Fase 2). La hipótesis técnica radica en que, al reconocer estas caras semánticas, podemos utilizar los nodos estructurales que habitan en ellas para completarlas matemáticamente. Con esos vértices estructurales proyectados, se aplica el algoritmo robusto LO-RANSAC [lebeda2012loransac] para extraer la ecuación final del muro.

4.1.5 Fase 5: Extracción de Fronteras y Texturizado

RANSAC devuelve una abstracción matemática infinita. Esta fase sirve para delimitar físicamente esa superficie utilizando las líneas proyectadas del *wireframe* (Fase 2) para recortar el plano infinito, estableciendo las fronteras reales del muro.

Una vez instanciado este polígono 3D cerrado y finito, se le aplica el texturizado. Para garantizar un mapeo UV de alta fidelidad, se hace uso de una homografía directa desde el fotograma que se encuentre más ortogonal a la normal del plano.

- **Resumen:** Las líneas del wireframe recortan el plano infinito creando el modelo 3D final, que luego es pintado con el fotograma más alineado posible de esa pared.

4.2 Infraestructura de la Base de Datos de Poses y Alineación Topológica

La captura asíncrona de datos urbanos a gran escala genera múltiples secuencias de video independientes, las cuales resultan en sub-mapas locales o trayectorias de cámara inconexas. El paradigma clásico comete el error de almacenar nubes de puntos densas directamente en una base de datos. Sin embargo, en esta propuesta arquitectónica **se prioriza almacenar el grafo de poses de la cámara en lugar de la geometría cruda.**

Esta decisión de diseño es crítica. Al guardar únicamente las transformaciones espaciales optimizadas ($SE(3)$) y las imágenes fuente, el sistema funciona como un “esqueleto” que es independiente del motor de renderizado. Como se ilustra en la Figura ??, esto garantiza que el *dataset* recolectado sea completamente agnóstico y reutilizable a futuro. Mañana más tarde, el mismo grafo espacial podrá alimentar no solo la reconstrucción de mallas poligonales actual, sino algoritmos de *3D Gaussian Splatting*, representaciones neuronales (NeRF) o sistemas de mapas interactivos y realidad aumentada.




FIGURA 4.5: Arquitectura de la Base de Datos de Poses. Al almacenar y alinear el grafo espacial en lugar de puntos tridimensionales masivos, el sistema actúa como un núcleo topológico versátil que puede alimentar múltiples tecnologías de reconstrucción a futuro.

El desafío fundamental radica en la alineación topológica de estas trayectorias. A nivel algorítmico, esto requiere resolver un problema de Optimización de Grafo de Poses (*Pose Graph Optimization*, PGO). Cuando existen co-visibilidades entre diferentes secuencias de video, el sistema extrae coincidencias y computa transformaciones de similitud $Sim(3)$ —las cuales ajustan la rotación, traslación y escala de forma simultánea— para anclar matemáticamente las trayectorias relativas sin necesidad de recalcular puntos.

Para mitigar la acumulación de error inercial y de escala (*drift*), intrínseco al rastreo monocular en distancias prolongadas, la infraestructura integra datos de telemetría GPS. Estos actúan como restricciones absolutas dentro del grafo de optimización. Esta arquitectura descentralizada y robusta garantiza la consistencia global a nivel metropolitano, facultando al sistema a ensamblar continuamente nuevos fragmentos de la ciudad sin la penalidad de tener que re-optimizar ninguna nube de puntos global desde cero.

4.3 Métricas de Evaluación y Entorno Experimental

Para evaluar rigurosamente la calidad de la reconstrucción y la eficiencia del modelo propuesto frente al estado del arte, se han definido métricas tanto geométricas como computacionales. Asimismo, se ha seleccionado un entorno de pruebas estandarizado que garantice la reproducibilidad del experimento.

4.3.1 Dataset de Evaluación: UrbanScene3D

Las pruebas cuantitativas se realizarán utilizando **UrbanScene3D** [shen2021urbanscene3d] un *dataset* a gran escala y simulador diseñado específicamente para la investigación en reconstrucción 3D y percepción urbana por visión estéreo y drones.




FIGURA 4.6: Representación de una de las ciudades del dataset UrbanScene3D. Provee secuencias de video de alta resolución, parámetros de cámara exactos y un modelo geométrico (*Ground Truth*) extremadamente preciso, lo que resulta fundamental para contrastar matemáticamente la fidelidad de la malla extraída (Fuente: Adaptado de [shen2021urbanscene3d]).

UrbanScene3D fue elegido por encima de otros repositorios porque ofrece secuencias de imágenes aéreas sintéticas y reales junto con un modelo topológico completo. Disponer del *Ground Truth* de la geometría arquitectónica permite evaluar sin margen de error la hipótesis del *pipeline* libre de MVS.

4.3.2 Métricas Geométricas

Estas métricas, extraídas del estándar del estado del arte, miden qué tan parecida es la topología reconstruida (P) respecto a la escena de referencia o *Ground Truth* (G).

- **RMSE(P, G) - Error Cuadrático Medio Posicional:** Cuantifica la desviación posicional absoluta promedio de los vértices extraídos frente a la malla real. Mide directamente cuánto se equivocó el algoritmo al ubicar la geometría en el espacio euclidiano. Se define como:

$$\text{RMSE}(P, G) = \sqrt{\frac{1}{|P|} \sum_{p \in P} \min_{g \in G} \|p - g\|_2^2} \quad (\text{IV.1})$$

Donde p y g representan puntos homólogos en ambas nubes.

- **$d_{CD}(P, G)$ - Distancia de Chamfer:** Es la métrica estándar por excelencia para evaluar mallas 3D. Intuitivamente, calcula, para cada punto de la reconstrucción P , cuál es su vecino más cercano en la geometría real G (evaluando Precisión), y viceversa desde G hacia P (evaluando Completitud). Se define formalmente como:

$$d_{CD}(P, G) = \frac{1}{|P|} \sum_{p \in P} \min_{g \in G} \|p - g\|_2^2 + \frac{1}{|G|} \sum_{g \in G} \min_{p \in P} \|p - g\|_2^2 \quad (\text{IV.2})$$

Un valor cercano a cero penaliza fuertemente las mallas que inventan "geometrías fantasma"(mala precisión) o que dejan huecos estructurales (mala completitud).

- **Error Absoluto Topológico (Normales):** Evalúa la integridad de las caras arquitectónicas y la preservación de los bordes duros de los edificios. En arquitecturas *Manhattan-world*, esto se mide mediante el error angular de las normales de las superficies:

$$\text{EAT}(P, G) = \frac{1}{|P|} \sum_{i=1}^{|P|} \arccos(|\mathbf{n}_{P,i} \cdot \mathbf{n}_{G,i}|) \quad (\text{IV.3})$$

Penaliza severamente el ruido estructural, como las paredes que parecen "derretidas." con deformaciones, típicas de los enfoques MVS cuando se confunden con reflejos en las ventanas.

4.3.3 Métricas Computacionales

Dado que el objetivo principal y la promesa de valor de la investigación es aniquilar el excesivo coste computacional del MVS clásico, se evaluarán dos parámetros operativos críticos de hardware:

- **Tiempo de Cómputo (Horas):** Se cronometrará el tiempo exacto transcurrido desde la ingesta de las imágenes hasta la exportación de la malla poligonal final. El objetivo es comprobar empíricamente una reducción logarítmica en los tiempos de inferencia.
- **Consumo máximo de memoria (Peak VRAM):** Mide la huella de memoria en gigabytes (GB) requerida en la tarjeta gráfica. Con esta métrica se busca demostrar empíricamente que extraer únicamente la abstracción geométrica requiere una fracción marginal de la VRAM comparado con densificar iterativamente millones de píxeles ciegos.